

# VOC

Voice of Customer

---

**NLP · IA Generativa**  
**RAG · Power BI**

**Isabela Rodríguez**  
**Duque**  
Ing. Analítica de Datos

**Prueba técnica – Científico(a) de AI**

## **Analítica conversacional para gestión de cobranza**

De conversaciones de WhatsApp a variables estructuradas, insights de negocio y una propuesta de asistencia inteligente basada en RAG.

42.607 mensajes · 1.197 conversaciones · análisis exploratorio con IA

# 1. Reto de negocio

Cinco preguntas orientaron el diseño técnico y analítico.

## OBJETIVO


**Entender por qué no pagan los clientes, qué hace el asesor, qué acciones se asocian con acuerdos y dónde se deteriora la experiencia.**

- |          |                           |                                                                           |
|----------|---------------------------|---------------------------------------------------------------------------|
| <b>A</b> | <b>Motivos de no pago</b> | ¿Cuáles son los principales motivos manifestados por el cliente?          |
| <b>B</b> | <b>Ofertas del asesor</b> | ¿Qué alternativas u ofrecimientos se presentan para lograr un acuerdo?    |
| <b>C</b> | <b>Efectividad</b>        | ¿Qué ofrecimientos o argumentos aparecen con mayor tasa de acuerdo?       |
| <b>D</b> | <b>Resumen</b>            | ¿Qué está ocurriendo en cada conversación?                                |
| <b>E</b> | <b>Experiencia</b>        | ¿Qué caracteriza las conversaciones con menor satisfacción o experiencia? |

**Regla clave: acuerdo = compromiso  
explícito + fecha específica**

## 2. Datos y calidad

La calidad del corpus se validó antes de construir variables con IA.



### Hallazgos de validación

- Los dos identificadores de conversación resultaron equivalentes.
- Los duplicados se concentraron en 10 conversaciones (0,84% del total).
- Se identificaron cuatro emisores: USUARIO, AGENTE, BOT y HSM.
- Después de eliminar solo duplicados exactos, se conservaron las 1.197 conversaciones.


### Resultado de la depuración

La variable `total_interacciones` pasó de una coincidencia inicial del 99,16% a una consistencia del 100% con el número real de mensajes.

*Esto reduce el riesgo de sesgo en las métricas posteriores.*

### 3. Metodología end-to-end

Del mensaje crudo al insight accionable.



**Principio de diseño**

Separar reglas determinísticas de negocio (por ejemplo, qué constituye un acuerdo) de la interpretación semántica realizada por el LLM.

## 4. IA Generativa + Prompt Engineering

El LLM transforma cada conversación en un registro analítico estructurado.

### Variables generadas

- Motivo y submotivo de no pago
- Oferta, tipo de oferta y argumento del asesor
- Acuerdo de pago y fecha comprometida
- Sentimiento del cliente
- NPS, satisfacción y facilidad cuando existen
- Experiencia inferida por IA (1–5)
- Factores negativos, resumen y recomendación


### Reglas incorporadas al prompt

- Usar AGENTE para identificar ofertas; BOT/HSM solo como contexto.
- No inventar información: ausencia = “No identificado” / null.
- Acuerdo solo con aceptación explícita y fecha específica.
- Separar NPS (0–10), satisfacción (1–7), facilidad (1–5) y experiencia inferida.
- Resumen máximo de tres oraciones y recomendación accionable.

Salida estructurada con esquema Pydantic

# 5. Validación piloto

Gold Set manual para verificar las variables más críticas.



## ¿Dónde estuvo la discrepancia?

La variable oferta\_asesor presenta solapamiento semántico entre categorías cercanas: reestructuración vs. nueva fecha; seguro asociado vs. orientación a otro canal.

Se conservó la métrica real; no se forzó un 100% artificial.



## Mejora propuesta

Separar la taxonomía en dos dimensiones:

- Tipo de solución refinanciación · seguro · nueva fecha · pago parcial
- Canal de gestión mismo asesor · otra área · canal especializado

# 6. Hallazgos: motivos y ofertas



La muestra procesada revela tanto fricciones operativas como dificultades reales de pago.



**Insight** 32,8% de la muestra corresponde a clientes que reportan haber pagado o estar al día: una señal clara de oportunidad en sincronización de recaudos y campañas.

# 7. Efectividad observada y visualización en Power BI

Las acciones concretas muestran mayor tasa de acuerdo en la muestra procesada.



**Nota metodológica** n=58. Las tasas describen asociaciones, no causalidad; además, “Acuerdo o compromiso de pago” puede solaparse conceptualmente con el resultado.



# 8. Experiencia del cliente: dónde se rompe

Las cinco conversaciones con peor experiencia concentran fricciones operativas y de resolución.



**Prioridad de mejora: resolver primero el problema operativo antes de continuar con presión de cobranza.**

# 9. Propuesta RAG

Asistente de cobranza grounded en conocimiento institucional vigente.



**Diseño recomendado: human-in-the-loop para casos ambiguos o de mayor riesgo.**

# 10. Recomendaciones de negocio

Prioridades accionables derivadas del análisis.

1

Sincronizar pagos y cobranza

Reducir contactos a clientes que ya pagaron mediante una actualización más rápida entre recaudo y campañas.

2

Discursos por motivo

Liquidez, desempleo, inconformidad o falta de extracto requieren rutas y argumentos diferentes.

3

Priorizar acciones concretas

Favorecer alternativas claras y ejecutables: fecha, monto, canal y condiciones explícitas.

4

Resolver en primer contacto

Reducir transferencias y entregar al asesor información suficiente para explicar y resolver en el mismo canal.

5

RAG como asistente

Estandarizar respuestas con información institucional vigente, trazable y sujeta a guardrails.

6

Monitorear experiencia

Usar sentimiento, encuestas y factores negativos para coaching, calidad y mejora continua.

# 11. Cierre: valor, límites y escalabilidad

Una prueba de concepto que demuestra el flujo completo y deja claro cómo llevarlo a producción.

## Valor entregado

- Conversaciones no estructuradas convertidas en variables de negocio.
- Reglas explícitas para detectar acuerdos de pago.
- Validación piloto con Gold Set y análisis de discrepancias.
- Visualización ejecutiva en Power BI.
- Propuesta RAG con evaluación técnica y de negocio.

## Limitaciones y siguiente paso

- Muestra de 58 conversaciones procesadas por restricciones de cuota de API.
- Gold Set piloto: ampliar antes de estimar desempeño definitivo.
- Taxonomía de ofertas requiere mayor exclusividad semántica.
- Escalar el mismo pipeline a las 1.197 conversaciones.
- Validar impacto con experimentos controlados y métricas de negocio.

**Conclusión: NLP + IA Generativa + RAG convierten la voz del cliente en decisiones más consistentes, medibles y escalables.**

# 12. Anexo técnico: Python + Notebook

Evidencia de implementación, reproducibilidad y estructura del entregable técnico.

## Extracto del pipeline en Python

```
def analizar_conversacion_final(texto):
    response = client.models.generate_content(
        model=modelo,
        contents=[
            PROMPT_SISTEMA_FINAL,
            construir_prompt_final_v3(texto)
        ],
        config=types.GenerateContentConfig(
            response_mime_type="application/json",
            response_schema=AnalisisConversacionV2,
            temperature=0.1
        )
    )

    resultado = response.parsed

    # Regla determinística de negocio
    if resultado.acuerdo_pago is False:
        resultado.fecha_acuerdo = None

    return resultado.model_dump()
```

*Salida estructurada con Pydantic · reintentos · fallback de modelos · checkpoints*

## Notebook documentado

- EDA y validación de calidad
- Reconstrucción de conversaciones
- Prompt Engineering y Gold Set
- Pipeline IA + análisis A-E

## Entregables técnicos

- Notebook .ipynb documentado
- Dataset analítico enriquecido
- Dashboard Power BI (.pbix)
- Presentación ejecutiva

*La API key se gestionó mediante Colab Secrets.*

# 13. Anexo técnico: prompts y medición de experiencia

Cómo se controló la extracción generativa y cómo se trataron satisfacción, NPS y experiencia.

## Extracto del prompt definitivo

Reglas de interpretación incluidas en el contexto del LLM:

- Usar AGENTE para ofertas y argumentos; BOT/HSM solo como contexto.
- Acuerdo = compromiso explícito + fecha específica.
- Si acuerdo\_pago = false → fecha\_acuerdo = null.
- No inventar información; ausencia = “No identificado” / null.
- Extraer por separado NPS, satisfacción y facilidad.
- Resumen máximo de tres oraciones + recomendación accionable.

## Medición de satisfacción y experiencia

|   |                |      |                                           |
|---|----------------|------|-------------------------------------------|
| 1 | NPS            | 0–10 | Dato explícito de recomendación           |
| 2 | Satisfacción   | 1–7  | Dato explícito sobre alternativas         |
| 3 | Facilidad      | 1–5  | Dato explícito de esfuerzo/facilidad      |
| 4 | Experiencia IA | 1–5  | Indicador inferido cuando no hay encuesta |

Criterio metodológico: las escalas se conservaron separadas; no se construyó un índice artificial que mezcle métricas con significados distintos.